

Sistema de Evaluación de Riesgo Crediticio en Tiempo Real con Azure Machine Learning

Caso de Estudio: Banco Digital PrestaAndina S.A. | MLOps y Despliegue de Inferencia en la Nube

Julio Cesar Rosero Porras

Ingeniero de Datos y Finanzas Cloud

🕒 Min 00:00 a 05:00

- Requerimientos, Problema de Negocio y Calculadora de Costos Azure

Karoll Dahian Ramirez Marulanda

Arquitecta de Solución y ML

🕒 Min 05:00 a 10:00

- Arquitectura Cloud en Azure, Pipeline Designer y Métricas ROC/AUC

Jose Fernando Luque Cajiao

Ingeniero MLOps y Presentador

🕒 Min 10:00 a 15:00

- Despliegue del Endpoint REST, DEMO en Vivo y Conclusiones

Contexto de Negocio y Problemática Financiera

1. Entidad y Operación

- Banco Digital PrestaAndina S.A.
- FinTech B2C especializada en microcréditos de libre destino y préstamos digitales.
- Operación 100% en canales virtuales en Colombia y Latinoamérica.
- Volumen creciente de más de 3,500 solicitudes mensuales de personas naturales.

2. Diagnóstico del Problema

- Cartera Vencida (Default): Se ubica en el 14.8%, muy por encima del umbral deseado (< 8%).
- Evaluación Crediticia Empírica: Reglas estáticas y comités de crédito manuales.
- Latencia Crítica: Tiempo de análisis de 24 a 48 horas por solicitante.
- Fuga hacia Competidores: Tasa de abandono del 35% por demora en el desembolso.

3. Objetivo Estratégico

- Decisión Automatizada en Tiempo Real: Respuesta crediticia en menos de 2 segundos.
- Modelos Predictivos en la Nube: Clasificación supervisada basada en historial financiero.
- Integración API REST: Consumo directo desde el portal web bancario.
- Gobernanza y Auditoría: Trazabilidad completa bajo directrices regulatorias bancarias.

Requerimientos Técnicos y Restricciones de Cómputo

Requerimientos del Sistema (RF / RNF)

- ✓ RF-01: Ingesta de 1,000 registros históricos con 21 variables financieras (monto, plazos, garantías, ahorros).
- ✓ RF-02: Pipeline automatizado de preprocesamiento, selección de variables, limpieza e imputación.
- ✓ RF-03: Partición estratificada (70% Entrenamiento / 30% Prueba) con evaluación comparativa (ROC/AUC ≥ 0.75).
- ✓ RF-04: Exposición del modelo mediante Endpoint REST HTTPS con autenticación por Bearer Token.
- ✓ RNF-01: Latencia de inferencia inferior a 2.5 segundos por transacción.
- ✓ RNF-02: Elasticidad total: el cómputo debe reducirse a 0 nodos en inactividad para evitar costos ociosos.
- ✓ RNF-03: Comunicaciones cifradas con TLS 1.2+ y gestión segura de llaves en Azure Key Vault.

Restricciones de la Infraestructura en Nube

- ⚠ Presupuesto Estudiantil Estricto: Saldo limitado a USD en suscripción Azure for Students.
- ⚠ Restricción de Cómputo CPU: Cuota de GPU en 0; uso exclusivo de instancias CPU económicas (Standard_DS11_v2, 2 vCPUs).
- ⚠ Directiva de Región Obligatoria: Política Azure sys.regionrestriction restringe despliegues a West US (Oeste de EE. UU.).
- ⚠ Mitigación de Cobros Fantasma: Configuración obligatoria de idle_time = 120s y min_nodes = 0.
- ⚠ Cumplimiento y Privacidad: Anonimización de datos personales para alineación con normativas de protección bancaria.

Selección de Alternativas y Cotización en Azure Calculator

Evaluación de Alternativas de Solución

Alternativa 1: IaaS Manual (VM Linux + Python Flask)

- Desventajas: Mantenimiento de SO, riesgo de cobro 24/7, sin trazabilidad ni MLOps nativo. DESCARTADA.

Alternativa 2: SaaS Cerrado (Cognitive Services genérico)

- Desventajas: Algoritmos de caja negra sin capacidad de personalizar variables crediticias. DESCARTADA.

Alternativa 3 (Seleccionada): Azure ML Designer PaaS

- Ventajas: Pipeline reproducible, gobernanza MLOps, despliegue REST en 1 clic y escalado automático a 0 nodos.

Estimación Oficial: Azure Pricing Calculator

Componente | Uso Estimado | Costo Estimado

- Azure ML Workspace: Nivel Estándar | .00 USD (Gratis)
- Storage Account (Blob LRS Hot): 5 GB | .10 USD / mes
- Compute Cluster (DS11_v2): 4 hrs uso | .56 USD
- Pipeline Endpoint: Inferencia Serverless | .00 USD (en reposo)
- Container Registry & Key Vault: 1 mes | .86 USD

TOTAL PROYECTO: ~.52 a .94 USD

(Representa menos del 4% del bono de USD otorgado por Azure for Students)

Propuesta de Diseño y Arquitectura en Azure

1. Capa de Datos y Persistencia

- Azure Blob Storage (LRS Hot): Almacenamiento seguro del archivo `german_credit_risk.csv`.
- Azure ML Data Asset: Conjunto de datos Tabular versionado e inmutable con 1,000 registros y 21 atributos.

2. Capa de Cómputo y Entrenamiento

- Azure ML Workspace (`mlw-credit-risk`): Entorno centralizado en región West US.
- Compute Cluster (`cluster-credit-risk`): Instancia `Standard_DS11_v2` con auto-escalado entre 0 y 1 nodo.

3. Capa de Inferencia y MLOps

- Model Registry: Almacén de modelos auditables (`model_spec.yaml` y pesos de árboles).
- Pipeline Endpoint Serverless: Expone el endpoint de canalización para inferencia en tiempo real.

4. Capa de Consumo y Seguridad

- Azure Key Vault: Gestión y custodia de credenciales y tokens de acceso.
- Canales Clientes: Terminal Python (`test_endpoint.py`), Postman y Portal Web del Banco.

Flujo de Trabajo del Pipeline en Azure ML Designer

1. Ingesta y Selección

german-credit-risk
+ Select Columns
in Dataset

Ingesta del Data Asset tabular de 1,000 filas. Se incluyen las variables predictivas y se descartan identificadores ruidosos.

2. Limpieza de Datos

Clean Missing
Data
(Replace with
Mean)

Tratamiento de valores ausentes e imputación en variables numéricas para garantizar integridad matemática.

3. Partición Estratificada

Split Data
(Fraction: 0.7 |
Seed: 42)

Separación rigurosa: 70% para Entrenamiento (700 casos) y 30% para Validación y Prueba (300 casos).

4. Algoritmo y Entrenamiento

Two-Class
Boosted Decision
Tree
+ Train Model

Ensamble de árboles potenciados por gradiente (GBDT). Aprende patrones no lineales sobre la etiqueta CreditRisk.

5. Puntuación y Evaluación

Score Model
+ Evaluate Model

Generación de probabilidades scored probabilities y cálculo de curvas ROC, AUC y matriz de confusión.

Resultados y Métricas de Evaluación del Modelo

Rendimiento Cuantitativo (Evaluate Model)

-  Área Bajo la Curva ROC (AUC): 0.812 (Meta del proyecto: ≥ 0.75). Indica alta capacidad de discriminación entre clientes cumplidos e insolventes.
-  Exactitud Global (Accuracy): 76.3% sobre los 300 casos no vistos de prueba.
-  Precisión (Precision): 78.5% en la detección de perfiles de riesgo.
-  Recuperación (Recall): 81.0% para identificar oportunamente clientes solventes.
-  F1-Score Ponderado: 0.797, demostrando equilibrio entre sensibilidad y especificidad.

Impacto en el Riesgo Financiero

-  Minimización de Falsos Positivos (Prestar a clientes de alto riesgo): La curva ROC permite ajustar el umbral de decisión a 0.55 para proteger la liquidez del banco.
-  Explicabilidad de Árboles (Gradient Boosting): Las variables de mayor peso predictivo resultaron ser:
 -  1. Saldo en cuenta corriente (CheckingAccount)
 -  2. Historial de pago previo (CreditHistory)
 -  3. Monto solicitado y plazo del crédito (CreditAmount / Duration)
 -  4. Tiempo en el empleo actual (EmploymentDuration)
-  Cumplimiento Auditoría: Modelo auditable conforme a las exigencias de la Superintendencia Financiera.

Capa MLOps y Despliegue del Servicio REST

1. Transformación de Inferencia

- Conversión automática en Azure Designer: Se genera Pipeline-Credit-Risk-Evaluation-real time inference.
- Se reemplaza el entrenamiento por el artefacto estático Trained Model.
- Se integra Apply Transformation para normalizar los nuevos datos de entrada en milisegundos.

2. Publicación de PipelineEndpoint

- Se publica el extremo endpoint-credit-risk.
- Alojado en el plano de control Serverless de Azure Machine Learning (West US).
- Costo en reposo de .00 USD/hora, eliminando costos de VMs encendidas innecesariamente.

3. Seguridad y Contrato API

- Endpoint REST oficial:
- <https://westus.api.azureml.ms/pipelines/v1.0/.../PipelineEndpointSubmit/...>
- Protocolo HTTPS cifrado con TLS 1.2+.
- Autenticación empresarial mediante Bearer Token expedido por Azure Active Directory.

DEMO EN VIVO: Consumo del Endpoint REST en Tiempo Real

CASO 1: Solicitante de Bajo Riesgo (Aprobado)

Perfil del Solicitante (payload_buen_cliente.json):

- Edad: 45 años | Empleo estable: ≥ 7 años
- Cuenta corriente: ≥ 200 DM | Ahorros: $\geq 1,000$ DM
- Vivienda: Propia | Monto: 1,500 DM | Plazo: 12 meses
- Historial: Créditos previos pagados puntualmente

✓ **RESPUESTA DEL SERVICIO EN TIEMPO REAL:**

- Código HTTP: 200 OK
- PipelineRunId: 605c0ce7-dac2-4b86-8eda-4e067ff26b69
- **Dictamen del Modelo: APROBADO (CreditRisk: Good)**
- Confianza Predictiva: 88.4%
- Decisión de Negocio: Desembolso digital automático.

CASO 2: Solicitante de Alto Riesgo (Rechazado)

Perfil del Solicitante (payload_mal_cliente.json):

- Edad: 21 años | Empleo: < 1 año
- Cuenta corriente: < 0 DM (Sobregiro) | Ahorros: < 100 DM
- Vivienda: Alquiler | Monto: 9,500 DM | Plazo: 48 meses
- Historial: Moras y retrasos registrados en el pasado

⚠ **RESPUESTA DEL SERVICIO EN TIEMPO REAL:**

- Código HTTP: 200 OK
- PipelineRunId: 6424d787-95f3-4b9d-b13b-e77ffdc13c80
- **Dictamen del Modelo: RECHAZADO (CreditRisk: Bad)**
- Probabilidad de Incumplimiento: 81.2%
- Decisión de Negocio: Solicitud denegada o con fiador.



Conclusiones Técnicas y Retorno sobre la Inversión (ROI)

1. Eficiencia y Elasticidad Cloud

- El clúster con auto-apagado (idle_time=120s, min_nodes=0) garantiza costo .00 cuando no se entrena.
- El Endpoint de canalización Serverless elimina cobros mensuales por máquinas virtuales dedicadas.
- La práctica consumió menos de .50 USD de los de regalo de Azure for Students.

2. Impacto Financiero en Producción

- Costo de operar la IA en Azure: ~ USD / mes.
- Reducir la mora en solo 1.5% sobre una cartera de ,000 USD representa un ahorro de ,500 USD / mes.
- El sistema genera un Retorno sobre la Inversión (ROI) superior al 6,000%, pagándose solo desde el mes 1.

3. Reproducibilidad en Equipo

- Repositorio GitHub estructurado:
<https://github.com/JoseLuqueC/Microproyecto3>.
- Los 3 integrantes cuentan con el dataset, scripts de prueba (.env) e infraestructura replicable en 10 minutos.
- Cumplimiento del 100% de los criterios de evaluación del profesor Oscar Mondragón.